מגישים: ישראל כהן 205812290 אבישי ויזל 205916364 וכפיר ענבל 209013168

פרוייקט גמר

למה בחרנו את הדאטה:
בחרנו בדאטה של מדד האוניברסיטאות כדי לגלות מה המדדים המשמעותיים ביחס לדירוג האוניברסיטאות בעולם.

ננסה לחזות את דירוג האוניברסיטה ע"פ הנתונים בשנת 2016, וע"י כך נוכל ללמוד מה הם המדדים שהכי השפיעו על הדירוג.

הנושא מעניין כמובן גם בראי אוניברסיטת בר אילן.

תיאור הדאטה:

הדאטה מורכב מטבלה בעלת 800 שורות, ו-13 עמודות. בכל שורה נמצאת מדידה של אוניברסיטה אחרת בשנת 2016. בעמודות נמצאים המדדים, ובעמודה הראשונה נמצא הדירוג הכולל.

עיבוד הדאטה:

- לאחר סינון תאים ריקים ותאים שהכילו מקף - מספר השורות ירד ל 702.
- חלק מהעמודות הכילו ערכים שלא הועברו לערך מספרי ישירות, כמו 73% ו- "1,223", לכן העברנו אותם ידנית לערכים מספריים

הסבר תוכן העמודות:

1) world_rank = מדד עולמי של האוניברסיטה
2) university_name = שם האוניברסיטה
3) country = המדינה בה האוניברסיטה ממוקמת
4) international = ציון עבור גיוון של אנשים ממדינות שונות (סטודנטים, אנשי סגל ומחקר)
5) teaching =(ציון עבור איכות למידה (סביבת הלמידה
6) research = (ציון עבור רמת מחקר(נפח, תקצוב ומוניטין
7) citations = ציון עבור עד כמה מחקרי האוניברסיטה מצוטטים(השפעת מחקרי האוניברסיטה על העולם)
8) income = ציון האוניברסיטה להכנסה בתעשייה(העברת ידע)
9) num_students = מספר הסטודנטים באוניברסיטה
10) student_staff_ratio = יחס בין מספר הסטודנטים למספר אנשי הסגל
11) international_students = (אחוז הסטודנטים הבינלאומיים (שהיגרו ממדינה אחרת
12) female_male_ratio = יחס בין מספר הנשים למספר הגברים באוניברסיטה
13) year = שנת המדידה

EDA

נתונים וגרפים על הדאטה:

התפלגות ציון איכות ההוראה באוניברסיטאות השונות:

יצרנו HeatMap כדי לגלות ולוודא אילו מהמדדים הם בקורלציה גבוהה ביותר עם ציון World_Rank אותו אנו רוצים לחזות:

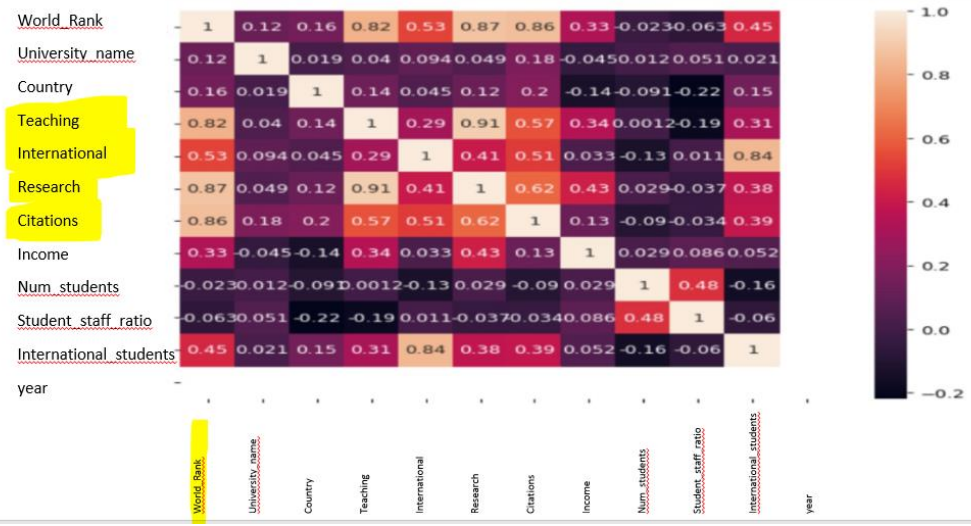

- <u>התפלגות ציון איכות ההוראה(teaching) באוניברסיטאות השונות:</u>

ניתן לראות כי רוב מובהק של האוניברסיטאות עם ציון באזור ה 40-10 מתוך 100. דבר זה מראה שעל פי המדד רוב האוניברסיטאות איכות ההוראה וסביבת הלמידה בהן היא בינונית-נמוכה יחסית ונמצאת מתחת לחציון.

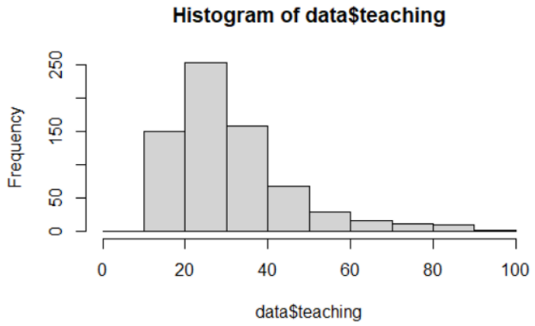

יחסי הסטודנטים מול הסגל בהשוואה לרמת ההוראה ורמת המחקר:

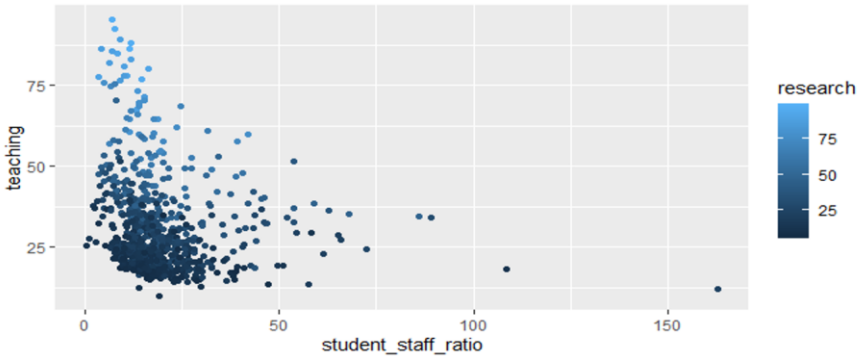

נראה שברוב <u>האוניבסיטאות</u> יש יחס די נמוך (סטנדרטי אפשר לומר) בין מספר הסטודנטים למרצים.
יש יותר סטודנטים מאשר מרצים בממוצע ביחס של כ-20 סטודנטים למרצה, ולא נמצא קשר בין יחס זה לבין רמת ההוראה ורמת המחקר.
אומנם, רואים כי יש קשר מובהק בין מדד ה-teaching לבין מדד ה-research.

<u>מאילו מדינות מגיעות 50 האוניברסיטאות הכי טובות?</u>

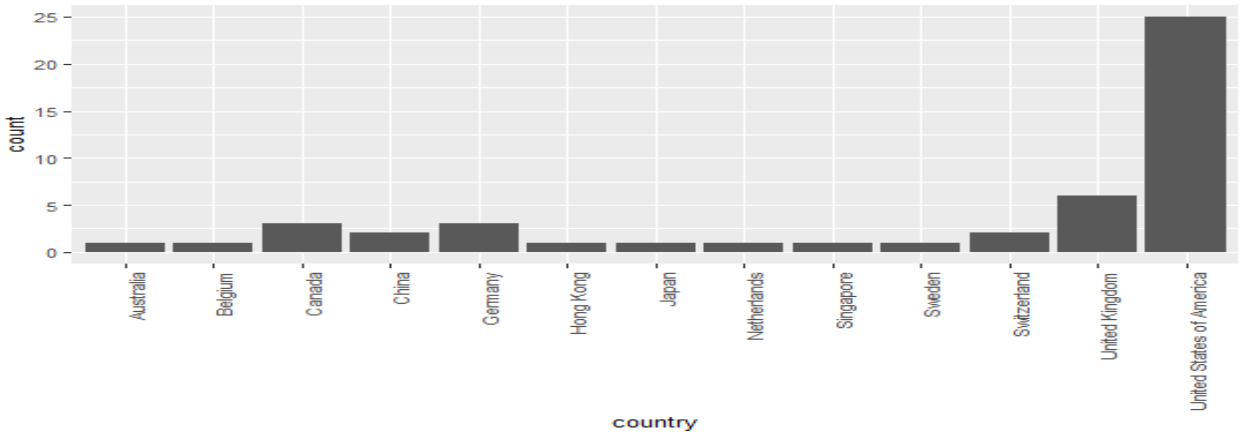

<u>אלגוריתמים:</u>

<u>עיבוד מקדים:</u> לשם ה-classification ויצירת labels, ביצענו חלוקה לקבוצות שונות לפי דירוג כל אוניברסיטה בצורה הבאה (השתמשנו בצורת הדירוג הזו לשאר סוגי האלגוריתמים להלן):

יצירת ה-labels:

<u>דירוג:</u>	10	9	8	7	6	5	4	3	2	1	0

טווח:	1 - 10	11 - 50	51 - 100	101 - 150	151 - 200	201 - 253	254 - 302	303 - 350	351 - 401	402 - 600	601 - 800

(טווח - כל האוניברסיטאות בטווח הדירוג 1-10 קיבלו label 10, המייצג את 10 האוני' הטובות ביותר)

אחרי שניקינו, הרצנו את אלגוריתמים שונים על ה-data בניסיון לחזות את ה- rank, תוצאות האלגוריתמים:

Decision Tree:

עיבוד מקדים:

ביצעתי את הלמידה ללא העמודות של ה-world_rank (אותה חוזים, אשר על כן לא רלוונטי ללמוד עליה),

עמודת ה-year (זאת השנה שאנו חוזים בה את הנתונים),

וכן עמודת ה-female_male_ratio, כיוון שיש בעיה בלא הצלחנו להתגבר עליה נכון לעכשיו (המספרים שם היו בפורמט שגרם ל-excel לחשוב שמדובר בתאריך, אחרי הרבה זמן שעבדתי כדי לשנות את זה למספר המקורי, המספרים שם נשארו כ-chars ולא כ-int, ניסיונות ארוכים להמרת העמודה\המרת היחס לתוכן העמודה העלו חרס בשלב זה).

התוצאות של עץ ההחלטה היו טובות ביותר עבור עומק 13 (העומק המקסימלי).

אסטרטגיית הלמידה:

בוצעו 300 אפוקים של למידה, בכל אפוק שהייתה תוצאה טובה יותר מה-current_best, נשמרו המשקלים והדיוק החזויים במקומם.

התוצאות:

Accuracy: 0.6303317535545023

Weights: [0.01947872 0.01354113 **0.16065597** 0.02119478 **0.28136656 0.37019189** 0.04502295 0.01782069 0.03941616 0.03131115]

משקלי העמודות לעיל בהתאמה משמאל לימין:

university_name, country, **teaching**, international, **research**, **citation**, income, num_students, student_staff_ratio, international_students.

ויזואליזציות:

מצורך משמאל גרף למידה, ציר Y הוא ה-accuracy, ציר X זה מספר האפוקים:

גרף הלמידה המוצג הוא עבור שיפורים בלבד, לכן רואים רק עלייה.

גרף עבור כלל ה accuracy בתהליך הלמידה:

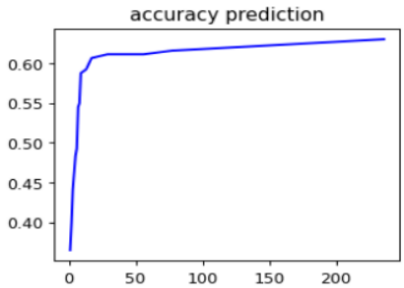

דיון:

כפי שניתן לראות, מודגש המדדים המשפיעים ביותר על הדירוג, התוצאות בקורלציה טובה מאוד עם ה heat-map שבוצע על הדאטה. נציין כי נתון גבוה יחסית מהשאר הוא מספר הסטודנטים, שמראה כי אוניברסיטאות טובות יותר מושכות אליהן יותר סטודנטים, דבר המעיד על הרמת האוניברסיטה כ-"אפקט העדר".

SVM:

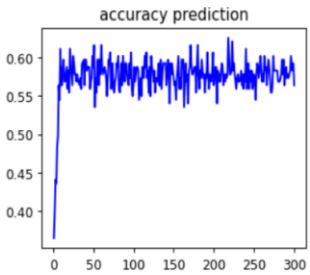

עיבוד מקדים:

המרתי את תוכן העמודות של ה country וה-university name מ-chars לייצוג מספרי.

הורדתי מהלמידה את עמודות:

female_male_ratio (מכיוון שלא הצלחתי להמיר לייצוג מספרי כפי שהוסבר באלגוריתם decision tree, ולכן האלגוריתם לא הצליח לרוץ)

עמודת ה-year, שגם בה אין צורך.

ה-world_rank כרגיל הוא ה-class החזוי ב-KSVM.

כהכנה נוספת ללמידה, ביצעתי ערבוב (shuffle) של השורות ב-data.

אסטרטגיית הלמידה:

חלוקת הdata נעשתה לאחר shuffle כאמור, ה-test קיבל 116 רצפים, האימון את כל השאר (584).

נבנו שני מודלים של SVM, הראשון עבורו הקרנל הוגדר vanilladot, מפריד לינארי,

לשני rbfdot, לא מפריד לינארי (לכן נצפה להצלחה גבוהה יותר).

אימנתי את שניהם, וקיבלתי data_classifier, בו השתמשתי כדי ליצור את טבלת ההסכמה של חיזוי world_rank של ה-test מול ה-world_rank האמיתי.

התוצאות:

<u>טבלת ההסכמה:</u>

FALSE TRUE

22 95

<u>באחוזים:</u>

FALSE TRUE

0.1880342 0.8119658

עבור: **vanilladot**

<u>טבלת הסכמה:</u>

FALSE TRUE

43 74

<u>באחוזים:</u>

FALSE TRUE

0.3675214 0.6324786

עבור: **rbfdot**

לאחר הצלחה יחסית טובה במודל השני, ניסיתי בkernel להשתמש ב"radial" וקיבלתי תוצאות טובות מאוד:

<u>באחוזים:</u>

FALSE TRUE

0.05982906 0.94017094

<u>טבלת ההסכמה:</u>

FALSE TRUE

7 110

דיון: המודל הלא לינארי, הצליח בשיעור ניכר הרבה יותר מאשר הלינארי, דבר המצביע על כך שהדאטה פריד בצורה טובה יותר משמעותית לא לינארית.

אכן, ניתן לראות זאת בפלט של אלגוריתם T-sne בתמונה הבאה:

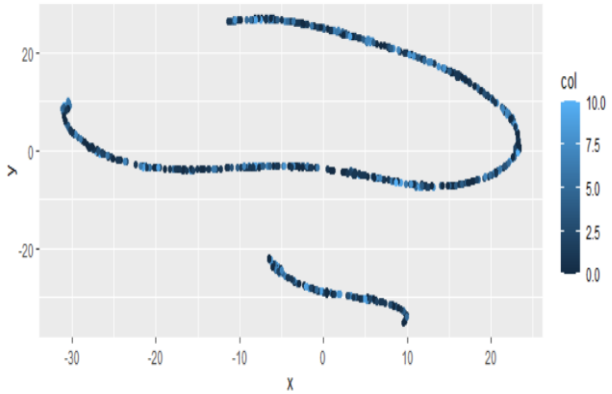

אמנם נוכל להגיע להפרדה מסוימת בקו לינארי כפי שהתוצאות הראו, אך בקו לא לינארי נצליח יותר. מבין ה-kernels הלא לינאריים, ה-"radial" הצליח מאוד, דבר שמראה שהדאטה סה"כ פריד בצורה לא לינארית בצורה טובה.

<u>Random forest</u>

יישמנו אלגוריתם Random forest בעל 1000 עצים, כדי לחזות את ציון האוניברסיטאות.

עיבוד מקדים:

ביצענו shuffling לדאטא לפני שביצענו split לאימון ו.test. הדאטא חולק על ידי פונקציית initial_split ללא העמודות הבאות: university_name, -country,-female_male_ratio, -year-,

הסיבה לכך היא שלמשל university_name וcountry הן עמודות שלא נכנסות לחישוב הציון (למירב ידיעתינו ועל פי בדיקה מקדימה באינטרנט של אופן חישוב הציון במדד זה). הסרנו את עמודת female_male_ratio משום שהיוותה בעיה במהלך הריצה של האלגוריתמים, זוהתה כטיפוס char במקום int למרות שניסינו לתקן זאת, ותיקנו את הערכים(המרנו לעשרוני) - ועדיין זה לא עבד. כך או כך, עמודה זו לא העמודה העיקרית בחישוב הציון גם, אז החלטנו להסירה מהחישוב באלגוריתם.

כמו בשיטות הקודמות, הדאטא סונן לשנת 2016 וסיננו מהדאטא NA's. world_rank - הקלאס שנרצה לחזות.

אסטרטגיית למידה:

קבענו 1000 עצים עבור המודל שלנו על ידי שימוש בחבילת Parsnip:

```
parsnip model object
Fit time:  571ms
Ranger result
Call:
 ranger::ranger(x = maybe_data_frame(x), y = y, num.trees = ~1000,      num.threads = 1, verbose = FALSE,
seed = sample.int(10^5,          1), probability = TRUE)
Type:                          Probability estimation
Number of trees:                 1000
Sample size:                     525
Number of independent variables:  8
Mtry:                          2
Target node size:                10
Variable importance mode:        none
Splitrule:                       gini
OOB prediction error (Brier s.):  0.328784
```

לאחר מכן, בדקנו את הביצועים של האימון במודל על פי מדדי ROC וAccuracy והשתמשנו בחבילת yardstick בכדי לחשב את מדדים אלה:

```
# A tibble: 1 x 3
  .metric .estimator .estimate
  <chr>   <chr>          <dbl>
 roc_auc hand_till        1
```

```
# A tibble: 1 x 3
  .metric  .estimator .estimate
  <chr>    <chr>          <dbl>
 accuracy multiclass     0.998
```

תוצאות ביצועי האימון יצאו overfitting. ניסינו להוריד את כמות העצים כדי לנסות להוריד את הסבירות לoverfit אך הניסיון לא צלח. ככל הנראה הסיבה לכך היא שכמות הדוגמאות שלנו עליה האלגוריתם התאמן מעטה מידי(בכל זאת יש גבול למספר האוניברסיטאות בעולם). בנוסף, סיבה מהותית גם כן היא שהאלגוריתם עצמו יכולים לזכור בקלות יותר את דאטא בסט האימון ולכן אם ניתן לו לחזות על פי הדאטא בסט האימון אז סיכוי גדול שנקבל overfit.

נבדוק את הביצועים על סט הtest על פי אותם מדדים:

```
# A tibble: 1 x 3
  .metric .estimator .estimate
  <chr>   <chr>          <dbl>
roc_auc hand_till       0.961
```

```
# A tibble: 1 x 3
  .metric  .estimator .estimate
  <chr>    <chr>          <dbl>
 accuracy multiclass     0.734
```

K-means

בשיטה זו בדקנו כיצד הדאטא מתחלק והאם הקשר הינו הדוק בין העמודות שנחשבים כקריטריונים לחישוב הדירוג העולמי של האוניברסיטאות על פי המדד. לשם כך, בחרנו ב5 עמודות מתוך הדאטא, 3 מתוכן הן הקריטריונים שנאמר על ידי מדד Times שבהן משתמשים לחישוב הדירוג והעמודה החמישית היא עמודה שבחרנו שרירותית מתוך אלה שלא נאמר שנבחרת להיות חלק מהחישוב:

1) "world_rank"
2) "teaching"
3) "research"
4) "citations"
5) "num_students"

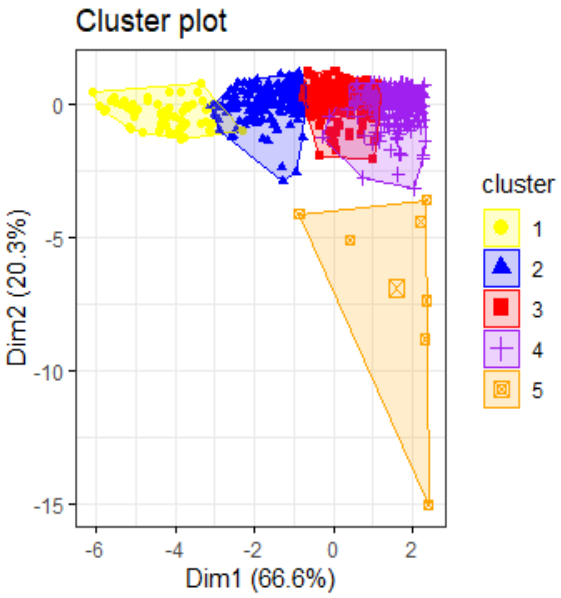

כפי שניתן לראות, אכן 3 העמודות הראשונות משפיעות הכי הרבה על העמודה הראשונה (הדירוג העולמי) והעמודה החמישית אינה מצומדת אל שאר העמודות.

KNN

נריץ את אלגוריתם **KNN-** k-nearest neighbors. האלגוריתם מקבל סט אימון וסט מבחן. עבור על דוגמה בסט מבחן, מתבצעת בדיקה מי הם K השכנים הקרובים ביותר, ועל פיהם הדוגמה מסווגת.

stratify train test split:

```
#remove labels, normalize and return labels
world_rank_col = data$world_rank
data = data %>% select(-world_rank)
data <- as.data.frame(scale(data))
data$world_rank = world_rank_col

cell_split <- initial_split(data, strata = world_rank)
cell_train <- training(cell_split)
cell_test  <- testing(cell_split)
```

extract train labels:

```
train_labels = cell_train%>% select(world_rank)
train_labels = train_labels[,1]
```

extract test labels

```
test_labels = cell_test%>% select(world_rank)
test_labels = test_labels[,1]
```

remove labels from data

```
cell_train = cell_train %>% select(-world_rank)
cell_test = cell_test %>% select(-world_rank)
```

אחרי שבנינו את הדאטה, ננסה להריץ את האלגוריתם עם K=1:

```
university_test_pred <- knn(train = cell_train, test = cell_test, cl = train_labels, k=1)

#print accuracy
tab <- table(university_test_pred,test_labels)
accuracy <- function(x){sum(diag(x)/(sum(rowSums(x)))) * 100}
print(accuracy(tab))
```

```
## [1] 61.05263
```

הדיוק הוא 61%. אבל מכיוון שבחרנו שרירותית K=1, נוכל לנסות לשפר את התוצאה ע"י חיפוש K אופטימלי:

```
#find best k
x <- c(1,3,5,7,9,11)
for (val in x) {
  university_test_pred <- knn(train = cell_train, test = cell_test, cl = train_labels, k=val)

  tab <- table(university_test_pred,test_labels)
  accuracy <- function(x){sum(diag(x)/(sum(rowSums(x)))) * 100}
  cat("K=", val,",accuracy=",accuracy(tab),"\n")
}

## K= 1 ,accuracy= 61.05263
## K= 3 ,accuracy= 63.68421
## K= 5 ,accuracy= 63.15789
## K= 7 ,accuracy= 59.47368
## K= 9 ,accuracy= 59.47368
## K= 11 ,accuracy= 62.10526
```

כפי שניתן לראות, החיפוש לא נתן לנו K טוב יותר. עכשיו ננסה שיטה אחרת לשיפור הדיוק- Sequential Forward Selection. מטרת השיטה היא למצוא תת קבוצה אופטימלית של פיצ'רים, כך שהדיוק יהיה מקסימלי:

```
library(FSinR)

evaluator <- wrapperEvaluator("knn")
searcher <- searchAlgorithm('sequentialForwardSelection')
results <- featureSelection(data, 'world_rank', searcher, evaluator)
```

The best features are:

```
results$bestFeatures

##      teaching international research citations income num_students
## [1,]        1             1        1         1      0            0
##      student_staff_ratio international_students
## [1,]                   0                      0
```

קיבלו תת קבוצה של הפיצ'רים. נבנה את הדאטה מחדש וננסה שוב את האלגוריתם:

```
new_data  = data %>% select(-income ,-num_students ,-student_staff_ratio ,-international_students)

#train test split
cell_split <- initial_split(new_data, strata = world_rank)
cell_train <- training(cell_split)
cell_test  <- testing(cell_split)

#extract train labels
train_labels = cell_train%>% select(world_rank)
train_labels = train_labels[,1]

#extract test labels
test_labels = cell_test%>% select(world_rank)
test_labels = test_labels[,1]

#remove labels from data
cell_train = cell_train %>% select(-world_rank)
cell_test = cell_test %>% select(-world_rank)

#find best k
x <- c(1,3,5,7,9,11)
for (val in x) {
```

```
  university_test_pred <- knn(train = cell_train, test = cell_test, cl = train_labels, k=val)
  tab <- table(university_test_pred,test_labels)
  accuracy <- function(x){sum(diag(x)/(sum(rowSums(x)))) * 100}
  cat("K=", val,",accuracy=",accuracy(tab),"\n")
}

## K= 1 ,accuracy= 80
## K= 3 ,accuracy= 78.94737
## K= 5 ,accuracy= 75.26316
## K= 7 ,accuracy= 75.26316
## K= 9 ,accuracy= 73.68421
## K= 11 ,accuracy= 74.21053
```

קיבלנו דיוק גבוה בהרבה- 80%! מה שאומר לנו שישנם פיצ'רים שמפריעים ללמידה של KNN.

AdaBoost:

אלגוריתם AdaBoost הוא אלגוריתם שמשתמש במספר גדול של עצי החלטה, בדומה ל Random Forest, אך עם שיטה שנקראת Boosting לשיפור האלגוריתם. מכיוון שהקוד לאלגוריתם לא עבד בשפת R, נאצלנו להשתמש בשפת פייתון:

```
data = pd.read_csv('C:\\Users\\avish\\CLionProjects\\sol_test.csv')

y = data['world_rank']
data = data.drop(columns=['world_rank'])
clf = AdaBoostClassifier(n_estimators=100, random_state=0)

(trainX, testX, trainY, testY) = train_test_split(data, y,
    test_size=0.25, stratify = y)

clf = clf.fit(trainX, trainY)

clf.score(testX, testY)

## 0.4126984126984127
```

LDA

נשתמש ב- LDA בשביל להוריד ממדים:

```
library(MASS)
library(ggord)

#train test split
cell_split <- initial_split(new_data, strata = world_rank)
cell_train <- training(cell_split)
cell_test  <- testing(cell_split)
linear <- lda(world_rank~., cell_train)

linear

## Coefficients of linear discriminants:

##                   LD1        LD2         LD3         LD4

## teaching      1.6518657 -0.5734547  2.36911982  0.09622907

## international 0.5246117  0.1638108  0.22659642  1.14875619

## research      2.2978830 -0.7356920 -2.46175226 -0.10217332

## citations     2.7635988  1.2746896  0.07518398 -0.71444198
```

```
## Proportion of trace:

##   LD1     LD2     LD3     LD4

## 0.9875 0.0111 0.0008 0.0006
```

זה אומר לנו ש- LDA1 מסביר לנו את רוב השונות בדאטה. נסתכל על LDA1:

```
LDA 1:

p <- predict(linear, cell_train)
par(mar=c(1,1,1,1))
ldahist(data = p$x[,1], g = cell_train$world_rank)
```

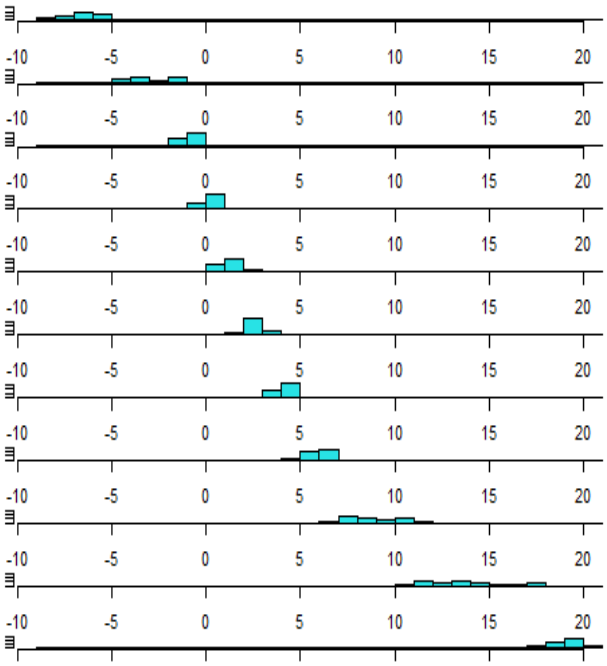

ישנה הפרדה ב LDA 1, אך גם קצת חפיפות בין הקלאסים.

LDA 2:

```
par(mar=c(1,1,1,1))
ldahist(data = p$x[,2], g = cell_train$world_rank)
```

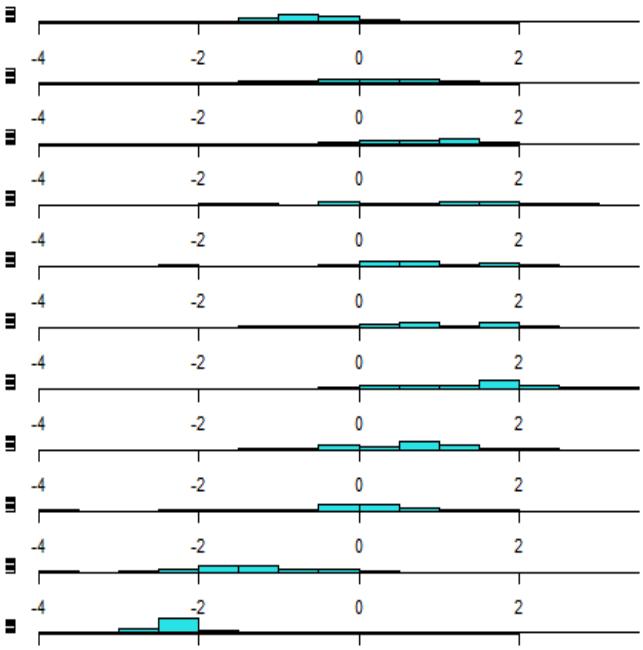

כפי שציפינו, החפיפה ב LDA 2 היא גדולה.

עכשיו נשרטט את ה- Bi-Plot, כדי לראות את פיזור הדאטה ע"פ LDA:

Bi-Plot:

```
library(ggord)
ggord(linear, as.factor(cell_train$world_rank))
```

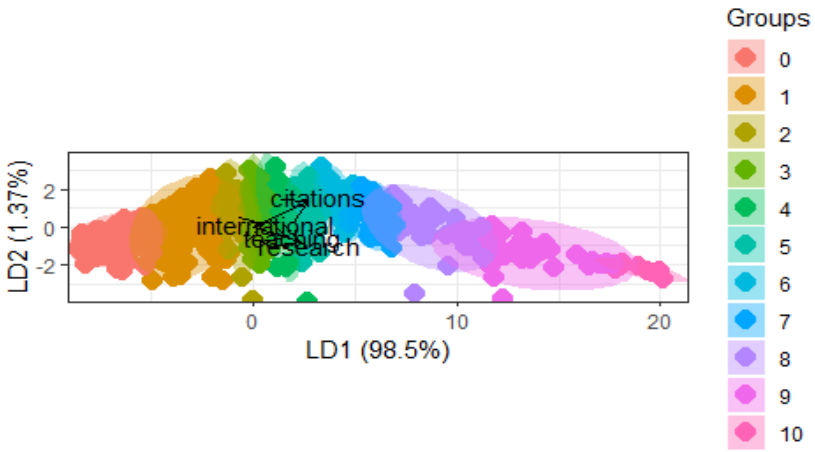

גם כאן אפשר לראות הפרדה טובה, אך מעט חפיפות.

כעת, נשתמש ב- LDA בשביל פרדיקציה:

```
p2 <- predict(linear, cell_test)$class

tab1 <- table(Predicted = p2, Actual = cell_test$world_rank)

tab1
```

```
sum(diag(tab1))/sum(tab1)
## 0.8631579
```

האלגוריתם נתן תוצאות מצוינות- 86% דיוק.

Predicted \ Actual	0	1	2	3	4	5	6	7	8	9	10
0	45	1	0	0	0	0	0	0	0	0	0
1	2	38	1	0	0	0	0	0	0	0	0
2	0	6	9	1	0	0	0	0	0	0	0
3	0	0	3	10	4	0	0	0	0	0	0
4	0	0	0	1	11	2	0	0	0	0	0
5	0	0	0	0	0	9	1	0	0	0	0
6	0	0	0	0	0	0	10	0	0	0	0
7	0	0	0	0	0	0	0	12	1	0	0
8	0	0	0	0	0	0	0	0	10	0	0
9	0	0	0	0	0	0	0	0	1	9	0
10	0	0	0	0	0	0	0	0	0	2	1

סיכום ומסקנות:

טבלה מסכמת:

אלגוריתם	דיוק
KNN	61
KNN with feature selection	80
Decision Tree	63
Random Forest	73
SVM (kernel with “radial”)	94
LDA	86
Adaboost	41

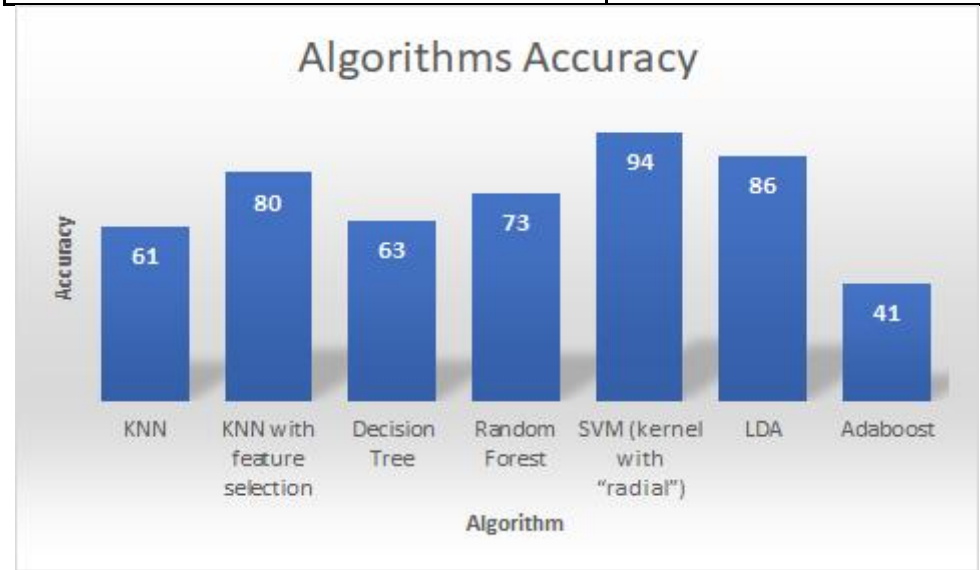

דיון בתוצאות:

- מהטבלה אנו רואים כי האלגוריתם שהצליח הכי טוב הוא SVM, ההצלחה שלו בראש ובראשונה תלויה בכך שלא לינארי, כי כשניסינו לעשות עבורו kernel לא לינארי הגענו לאחוזי הצלחה באזור 60.

- עם זאת, ה LDA מוריד מימדים, ומסווג לינארית, ולכן ציפינו שהציון שלו יהיה נמוך יחסית, אך הוא הגיע לציון כמעט הטוב ביותר. איך זה מסתדר? ככל הנראה, הורדת המימדים של ה LDA עוזרת לבצע בכל זאת סיווג לינארי.
- אלגוריתם ה Adaboost היה נמוך בהרבה מ-Random forest, שזה מפתיע בהתחשב בעובדה ש Adaboost הוא שיפור שלו. חיפשנו וראינו שהסיבה יכולה להיות dataset קטן יחסית, שאיתו אלגוריתמי ה- boosting פחות טובים בסיווג שלהם.
- עשינו feature selection רק עם אלגוריתם KNN. מכיון שהוא שיפר מאוד את התוצאות, אפשר לומר שישנם עמודות שמפריעות לחיזוי טוב. יכול להיות שאם היינו עושים feature selection לשאר האלגוריתמים, היינו מקבלים תוצאות טובות יותר.
- ניתן לומר שהצלחת ה-decision tree לא כ"כ טובה בגלל שה-split על ה-data שהוא עשה לא הצליחה להפריד בצורה טובה את כל הפיצ'רים כדי ליצור קלסיפיקציה טובה ועל בסיסה חיזוי טוב.
- כצפוי, Random forest הצליח יותר טוב מ Decision trees, מכיון ש RF מתבסס על הרבה עצי החלטה, ולכן מקבל החלטה טובה יותר.

ביבליוגרפיה:

מקור הנתונים: https://www.kaggle.com/mylesoneill/world-university-rankings

קוד:

טעינת ה-data:

```
install.packages("tidyverse")
library (tidyverse)
data <- read_csv("C:\\Users\\Israel\\Desktop\\ML & application to biological data analysis\\Final project\\archive\\timesData -
UsedWithLabels.csv")
```

סינון:

```
data = data %>% filter(year == 2016)
data[data==""]<-NA
data[data=="-"]<-NA
data<-data[complete.cases(data),]
```

קוד הגרפים:

1. hist(data$teaching) # plot histograma type
2. hist(data$research)
3. ggplot(data = data, mapping = aes(x=student_staff_ratio,y = teaching)) +geom_point(mapping = aes(x=student_staff_ratio, y = teaching))+geom_point(mapping = aes(colour = research))
4. ggplot(data = data, mapping = aes(x = income, y=research))+geom_smooth(method="lm")+geom_point(mapping = aes(x = income, y=research))+geom_point(mapping = aes(colour = teaching))
5. ggplot(data = data, mapping = aes(x=research,y = teaching)) + geom_smooth(method="lm") +geom_point(mapping = aes(x=research, y = teaching))
6. ggplot(data = data, mapping = aes(x = income, y=research))+ geom_smooth(method="lm") +geom_point(mapping = aes(x = income, y=research))+geom_point(mapping = aes(colour = female_male_ratio))
7. ggplot(data = data, mapping = aes(y = research, x=world_rank))+ geom_smooth(method="lm") +geom_point(mapping = aes(y = research, x=world_rank))+geom_point(mapping = aes(colour = female_male_ratio))
8. best_uni = filter(data,world_rank >=9)
   ggplot(data = new_data2) + geom_bar(mapping = aes(x = country))+ theme(text = element_text(size=10), axis.text.x = element_text(angle=90, hjust=1))

supplementary- קוד עבור האלגוריתמים:

1.

```
Decision Tree: (python)
#py_install("pandas")
#py_install("matplotlib")
#py_install("seaborn")
#py_install("scikit-learn")
import numpy as np
```

```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn import tree
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder

df = pd.read_csv("C:/Users/Israel/Desktop/ML & application to biological data analysis/Final project/archive/timesData -
UsedWithLabels.csv")
df = df.dropna() #drop nans rows
LE = LabelEncoder()
df['country'] = LE.fit_transform(df['country'])
df['university_name'] = LE.fit_transform(df['university_name'])
features0 = df.drop(['world_rank','female_male_ratio','year'], axis=1 )
features = np.array([features0])
labels0 = df.pop("world_rank")
labels = np.array([labels0])
X_train, X_test, y_train, y_test = train_test_split(
    features0, labels0,
    test_size=0.3,
    random_state=42,
)
max_pred = 0.0001
best_depth = 0
pred_array = []
i_lst = []
pred_lst = []
i_for_depth = 0.0
accuracy = 0.0
j=0
for i in range(300):
  j=i+1
  print (j)
  clf = tree.DecisionTreeClassifier(criterion='gini', splitter='best', max_depth=j, min_samples_split=2, min_samples_leaf=1,
min_weight_fraction_leaf=0.0, max_features=None, random_state=None, max_leaf_nodes=None, min_impurity_decrease=0.0,
min_impurity_split=None, class_weight=None, ccp_alpha=0.0)

  clf.fit(X = X_train, y = y_train)
  clf.feature_importances_ # [ 1.,  0.,  0.]
  accuracy = clf.score(X=X_test, y=y_test)

  if (max_pred <= accuracy):
    best_depth = clf.get_depth()
    pred_array =  clf.predict(X_test)
    max_pred = accuracy # 1.0
    print("better accuracy: ",max_pred)
    best_wight = clf.feature_importances_ # [ 1.,  0.,  0.]
  pred_lst.append(accuracy)
  i_lst.append(j)

print("best_depth:",best_depth, "pred_array:",pred_array,"max_pred:",max_pred,"best_wight:",best_wight)

fig = plt.figure(figsize=(10,5))
ax = fig.add_subplot(111)
plt.plot(i_lst,pred_lst,"-b");

ax.set_title('accuracy prediction')
ax.set_xlabel("index")
ax.set_ylabel("accuracy")
plt.show()
plt.close()
```

2. SVM:

```
#R code:

library (tidyverse)
data <- read_csv("C:\\Users\\Israel\\Desktop\\ML & application to biological data analysis\\Final project\\archive\\timesData -
UsedWithLabels.csv")

data = data %>% filter(year == 2016)
data[data==""]<-NA
data[data=="-"]<-NA
data<-data[complete.cases(data),]

#changin country & university name to numeric representation:
data$country <- as.factor(data$country) #convert the string from character to factor
data$university_name <- as.factor(data$university_name) #convert the string from character to factor
#data = data[,-2] #remove country #if factor above doesnt work somewhy
#data = data[,-2] #REMOVE UNI' NAME
  #do twice,rmv female male ration as its a chr col, 2T to remove year as well
data = data[,-12]
data = data[,-12]
#else do only once:
#data = data[,-13] #REMOVE year
```

```
#shuffling the data by rows:
data = data[sample(1:nrow(data)),]

#Doing scaling:
#scaleddf <- as.data.frame(sapply(data, function(i) if(is.numeric(i)) scale(i) else i)) #the algo will do it as well, so meybe not
needed
#data.frame(round(scales::rescale(-scaleddf$world_rank, to = c(1, 100)))) #rescale 1 column
#need to check rescaling all column altogether
#data <- data.frame(round(scales::rescale(-scaleddf$count, to = c(1, 100))))
#rescale <- function(x) (x-min(x))/(max(x) - min(x)) * 100
#data <- rescale(data)
#data
#install.packages("kernlab")
#install.packages("ISLR")
library(tidyverse)    # data manipulation and visualization
library(kernlab)      # SVM methodology
library(e1071)        # SVM methodology
library(ISLR)         # contains example data set "Khan"
library(RColorBrewer) # customized coloring of plots

#make any negative num to 0
data[data < 0] <- 0

#splitting to train and test
data_train <- data[118:702, ]
data_test <- data[1:117, ]

#Building the actual model:
data_classifier <- ksvm(world_rank ~ ., data = data_train, kernel = "vanilladot")
#data_classifier <- ksvm(world_rank ~ ., data = data_train, kernel = "rbfdot")

data_classifier

data_predictions <- floor(predict(data_classifier, data_test)+0.5) #added floor
#data_predictions <- ceiling(predict(data_classifier, data_test)-0.5) #added ceiling
#data_predictions <- trunc(predict(data_classifier, data_test)) #added ceiling

#make any negative num to 0
data_predictions[data_predictions < 0] <- 0
head(data_predictions)
table(data_predictions, data_test$world_rank)
agreement <- data_predictions == data_test$world_rank
table(agreement)
#in percentage
prop.table(table(agreement))
#Avg 60% success rate. Lets move on to improving the model performance:
#There are many kernal functions for SVM, but a standard Gaussian Radial basis function (RBF) kernal is a good place to start.
#We'll use the ksvm() function here:

WR_classifier_rbf <- ksvm(world_rank ~ ., data = data_train, kernel = "rbfdot") #NOT STREIGHT LINE
#WR_classifier_rbf <- ksvm(world_rank ~ ., data = data_train, kernel = "vanilladot") #STREIGHT LINE
#Create a prediction for this new model:
#WR_predictions_rbf <- floor(predict(WR_classifier_rbf, data_test)+0.5)
WR_predictions_rbf <- ceiling(predict(WR_classifier_rbf, data_test)-0.5)

#And compare it to the previous model:
agreement_rbf <- WR_predictions_rbf == data_test$world_rank
table(agreement_rbf)
prop.table(table(agreement_rbf))

WR_classifier_rbf <- ksvm(world_rank ~ ., data = data_train, kernel = "radial")
#Create a prediction for this new model:

#WR_predictions_rbf <- floor(predict(WR_classifier_rbf, data_test)+0.5)
WR_predictions_rbf <- ceiling(predict(WR_classifier_rbf, data_test)-0.5)


#And compare it to the previous model:
agreement_rbf <- WR_predictions_rbf == data_test$world_rank
table(agreement_rbf)
prop.table(table(agreement_rbf))
```

T-sne:

```
#R:
#install.packages("Rtsne")
library(ggplot2)
library(Rtsne)
tsne_out <- Rtsne(data)
tsne_plot <- data.frame(x = tsne_out$Y[,1], y = tsne_out$Y[,2], col = data$world_rank)
ggplot(tsne_plot) + geom_point(aes(x=x, y=y, color=col))

Random Forest:
```

```r
### Importing libraries ###
library (tidyverse)
library(ggplot2)
library(tidymodels)
library(modeldata)
library(vip)
library(yardstick)

### Loading data ###
data <- read.csv(file = "./timesData - UsedWithLabels-fixed FMRatio.csv")
###Preprocessing the data###
#Removing NA's
data[data==""]<-NA
data[data=="-"]<-NA
data<-data[complete.cases(data),]
#Filtering for year 2016
data = data%>%filter(year == 2016)

data %>%
  count(world_rank) %>%
  mutate(prop = n/sum(n))

#Shuffling the data by rows:
data = data[sample(1:nrow(data)),]


###Splitting the data###

#Selecting to remove the columns: university_name, country,female_male_ratio and year:
data_split <- initial_split(data %>% select(-university_name, -country,-female_male_ratio,-year), strata = world_rank)

data_train <- training(data_split)
data_test  <- testing(data_split)

#Training set proportions by world_rank
data_train %>%
  count(world_rank) %>%
  mutate(prop = n/sum(n))

#Test set proportions by world_rank
data_test %>%
  count(world_rank) %>%
  mutate(prop = n/sum(n))

### Random Forest Modelling ###

rf_mod <-
  rand_forest(trees = 1000) %>%
  set_engine("ranger") %>%
  set_mode("classification")

#set.seed(234)
rf_fit <-
  rf_mod %>%
  fit(factor(world_rank) ~ . , data = data_train)
rf_fit


### Estimating performance ###
rf_training_pred <-
  predict(rf_fit, data_train) %>%
  bind_cols(predict(rf_fit, data_train, type = "prob")) %>%
  # Add the true outcome data back in
  bind_cols(data_train %>%
              select(world_rank))

rf_training_pred %>%                # training set predictions
  roc_auc(truth = factor(world_rank), c(.pred_0,.pred_1,.pred_2,.pred_3,.pred_4,
                                .pred_5,.pred_6,.pred_7,.pred_8,.pred_9,.pred_10))


rf_training_pred %>%                # training set predictions
  accuracy(truth = factor(world_rank), .pred_class)


## Lets see how the model performs on the test data:

rf_testing_pred <-
  predict(rf_fit, data_test) %>%
  bind_cols(predict(rf_fit, data_test, type = "prob")) %>%
  bind_cols(data_test %>% select(world_rank))

rf_testing_pred %>%                   # test set predictions
  roc_auc(truth = factor(world_rank), c(.pred_0,.pred_1,.pred_2,.pred_3,.pred_4,
                                        .pred_5,.pred_6,.pred_7,.pred_8,.pred_9,.pred_10))
```

```
rf_testing_pred %>%                   # test set predictions
  accuracy(truth = factor(world_rank), .pred_class)
```

```
5.K-means:
### Importing libraries ###
library(dplyr)
library(stats)
library(ggpubr)
library(factoextra)
### Data Loading ###
data <- read.csv(file = "./timesData - UsedWithLabels-fixed FMRatio.csv")

### Filtering NA's ###
data[data==""]<-NA
data[data=="-"]<-NA
data<-data[complete.cases(data),]

### Filtering to year 2016 ###
data = data%>%filter(year == 2016)

### Creating dataframe from the data with only numeric columns ###
world_ranks_z <- as.data.frame(lapply(data[,c("world_rank","teaching","research","citations","num_students")], scale))
### Clustering the data to 5 clusters ###
worldrank_clusters <- kmeans(scale(data[,c("world_rank","teaching","research","citations","num_students")]), 5, nstart = 1)


### Plotting the clusters ###

fviz_cluster(worldrank_clusters, data = world_ranks_z,
             palette = c("yellow","blue","red","purple","orange"),
             geom = "point",
             ellipse.type = "convex",
             ggtheme = theme_bw()
)
```